Modelowanie Ryzyka Kredytowego

Kamil Koźbiał 131948

Zbiór danych

W projekcie wykorzystano ogólnodostępny zbiór danych z portalu kaggle zawierający informacje o **32 581** osobach ubiegających się o kredyt. Dane obejmują m.in.: wiek, dochód, długość zatrudnienia, status mieszkaniowy, historię kredytową, cel oraz parametry kredytu (kwota, oprocentowanie).

Zmienną celu jest **loan_status**, gdzie:

1 oznacza, że osoba znalazła się w zaległości (default),
0 oznacza, że osoba spłaciła kredyt prawidłowo.

Cel projektu

Celem projektu jest zbudowanie modelu predykcyjnego, który na podstawie danych osobowych oraz informacji o kredycie pozwoli przewidzieć, czy dana osoba znajdzie się w stanie zaległości kredytowej. Projekt wspiera proces oceny ryzyka kredytowego, umożliwiając lepsze decyzje finansowe z minimalnym wykorzystaniem czynnika ludzkiego w procesie ewaluacji.

Nazwa zmiennej	Opis
person_age	Wiek
person_income	Roczny dochód
person_home_ownership	Status mieszkaniowy
person_emp_length	Długość zatrudnienia (w latach)
loan_intent	Cel kredytu
loan_grade	Klasa kredytu
loan_amnt	Kwota kredytu
loan_int_rate	Oprocentowanie
loan_status	0 – brak zaległości, 1 – zaległości
Loan_percent_income	Odsetek dochodu przeznaczony na kredyt
cb_person_default_on_file	Historia wcześniejszych zaległości

Hipotezy badawcze

1. Branie kredytu na konsolidację zadłużenia zwiększa prawdopodobieństwo niewypłacalności.

2. Wyższy odsetek pensji przeznaczany na spłatę zobowiązań zwiększa prawdopodobieństwo niewypłacalności.

3. Osoby posiadające nieruchomości z mniejszym prawdopodobieństwem będą niewypłacalne.

4. Osoby, które posiadają historię zadłużenia z większym prawdopodobieństwem będą wpadać w zadłużenie.

Rozkłady wybranych zmiennych

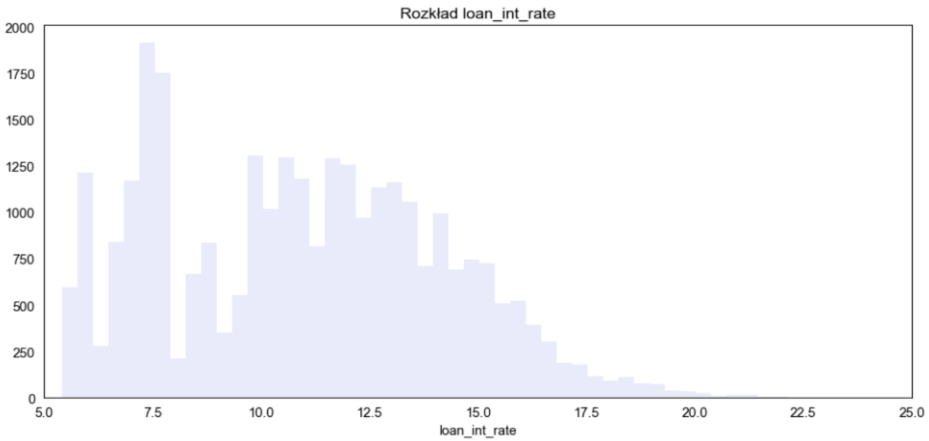

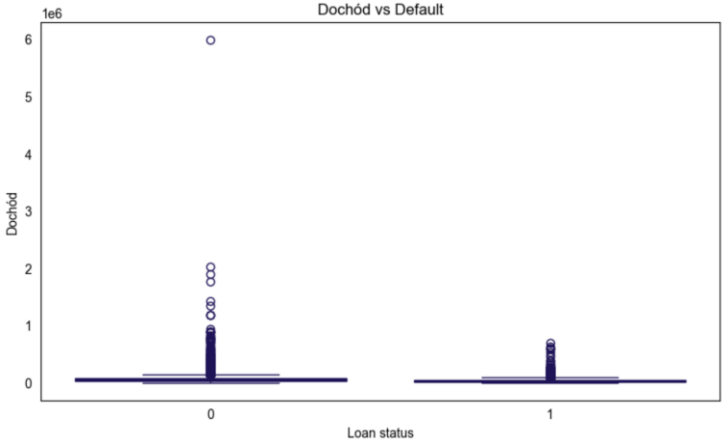

Rozkład oprocentowania pożyczek jest prawoskośny, z najwyższą koncentracją w przedziale 6–12% (szczególnie wokół 7–8%), a rzadziej występują wyższe stopy powyżej 15%.

Wykres pokazuje, że osoby, które nie zalegają ze spłatą, mają nieco wyższy medianowy dochód oraz większą zmienność, podczas gdy w grupie z defaultem dochody są ogólnie niższe i bardziej skumulowane wokół niższych kwot.

Macierz korelacji

- Najsilniej skorelowane są wiek klienta i długość historii kredytowej (r≈0,86) – należy **wykluczyć** jedną z tych zmiennych z analizy, aby uniknąć problemu współliniowosci.
- Udział raty w budżecie oraz oprocentowanie kredytu wykazują się największym współczynnikime korelacji ze zmienną celu.
- Pozostałe współczynniki korelacji są słabe, co wskazuje na konieczność uwzględnienia **wielu zmiennych** w modelach predykcyjnych.

Inne wizualizacje

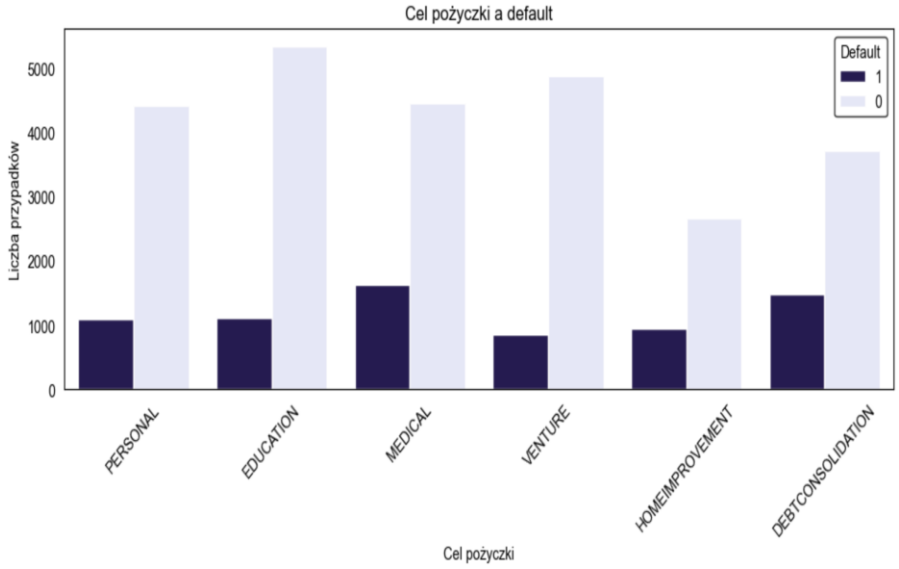

- Najwięcej przypadków niewywiązania się ze spłaty występuje przy pożyczkach na **medyczne** zabiegi oraz **konsolidację zadłużenia**, zarówno pod względem bezwzględnych liczb jak i udziału.
- Pożyczki na **edukację** i **inwestycje** cechuje stosunkowo niski odsetek defaultów, co sugeruje, że wnioskodawcy na te cele lepiej radzą sobie ze spłatą.
- Ogólny rozkład pokazuje, że czas spłaty i profil ryzyka różnią się znacząco w zależności od przeznaczenia środków.

Transformacja danych

Kodowanie zmiennych

Zmienne takie jak person_home_ownership, loan_grade oraz loan_intent zostały zakodowane za pomocą funkcji get_dummies.

Usunięcie braków danych

Wszystkie wiersze zawierające brakujące wartości zostały usunięte, aby uniknąć błędów podczas trenowania modeli.

Standaryzacja zmiennych

Dane zostały przekształcone przy użyciu standardyzacji (metoda StandardScaler), tak aby każda zmienna numeryczna miała średnią 0 i odchylenie standardowe 1.
Jest to szczególnie istotne w przypadku modeli takich jak regresja logistyczna, które są wrażliwe na różnice skali pomiędzy zmiennymi.

Podział zbioru na testowy i treningowy

Procedura SMOTE

Procedura SMOTE

Zmienna loan_status, która pełni w analizie rolę **zmiennej celu (target variable)**, jest **niezbilansowana** – około 78% przypadków stanowią osoby bez zaległości (No Default), a jedynie 22% to osoby, które miały zaległości w spłacie (Default).

Taka nierównowaga klas może prowadzić do sytuacji, w której model będzie preferował dominującą klasę i błędnie pomijał przypadki defaultu.

Aby zminimalizować to ryzyko i zwiększyć zdolność modelu do wykrywania przypadków zaległości, przed etapem modelowania zbiór treningowy zostanie zrównoważony przy użyciu metody **SMOTE (Synthetic Minority Over-sampling Technique)**.

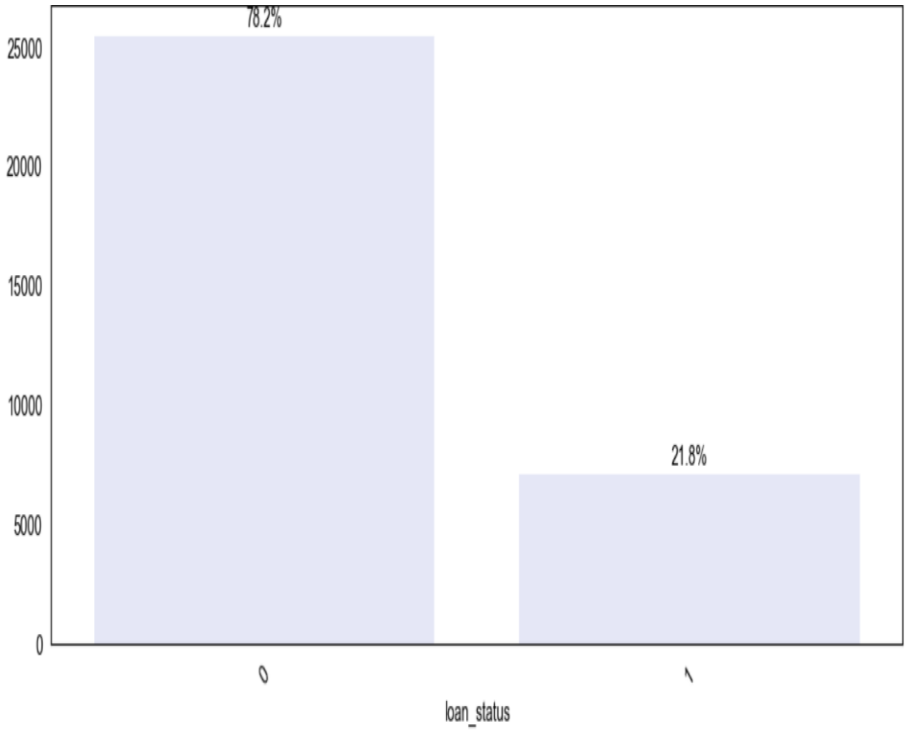

Założenia

W ramach projektu przetestowano różne algorytmy klasyfikacyjne w celu wyłonienia najskuteczniejszego modelu do prognozowania ryzyka niewypłacalności. W analizie uwzględniono m.in. regresję logistyczną, drzewa decyzyjne, Random Forest, SVM, sieci neuronowe oraz metody boostingu gradientowego (XGBoost, LightGBM, CatBoost).

W niniejszym raporcie szczegółowo omówiono działanie i wyniki regresji logistycznej, lasu losowego, sieci neuronowych oraz trzech popularnych algorytmów z rodziny gradient boosting: XGBoost, LightGBM i CatBoost.

Regresja logistyczna

Model dobrze radzi sobie z poprawną klasyfikacją przypadków bez zaległości, jednak ma niższą efektywność w wykrywaniu sytuacji z zaległościami, co potwierdza recall dla klasy 1 na poziomie 0,54.

Wysoka ogólna dokładność (0,86) jest przede wszystkim efektem przewagi przypadków bez zaległości w zbiorze danych.

Niska czułość (recall) dla klasy 1 oznacza, że wiele rzeczywistych przypadków zaległości może zostać przeoczonych.

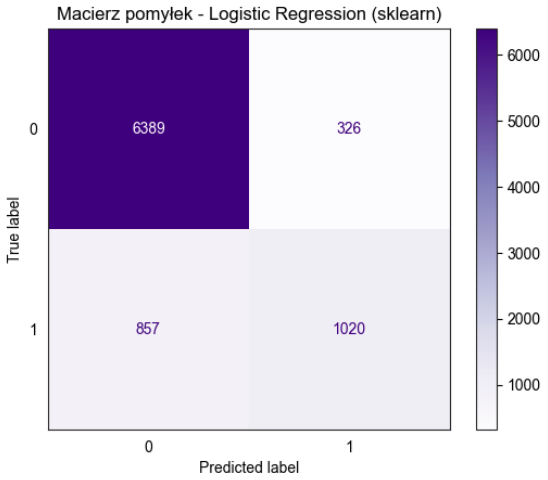


```
=== Wyniki regresji logistycznej (sklearn) ===
Accuracy: 0.8623
              precision    recall  f1-score   support

           0       0.88      0.95      0.92      6715
           1       0.76      0.54      0.63      1877

    accuracy                           0.86      8592
   macro avg       0.82      0.75      0.77      8592
weighted avg       0.85      0.86      0.85      8592
```

Regresja logistyczna

ROC & Precision-Recall curve

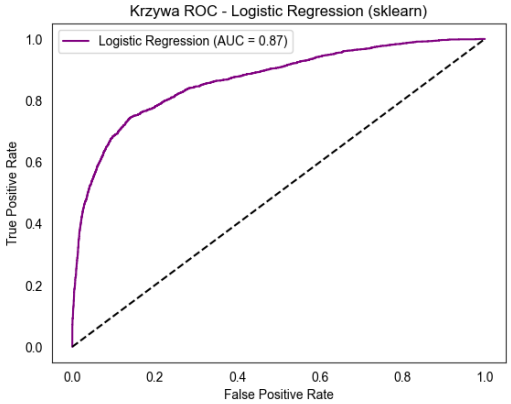

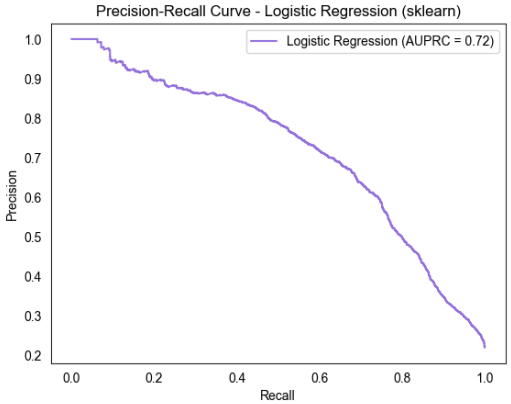

Model regresji logistycznej osiągnął wartość AUC równą **0.87**, co świadczy o jego **dobrej zdolności do rozróżniania klas pozytywnych i negatywnych**. Kształt krzywej ROC wskazuje na wysoką skuteczność modelu przy jednoczesnym ograniczeniu liczby fałszywie pozytywnych wyników.

Model regresji logistycznej wykazuje umiarkowanie dobrą wydajność z AUPRC na poziomie 0.72, ilustrując typowy kompromis między precyzją a TPR (True Positive Rate) w zależności od progu klasyfikacji.

Interpretacja wyników

Najsilniejszym czynnikiem ryzyka niewypłacalności jest wysoki stosunek pożyczki do dochodu – jeśli procent dochodu przeznaczony na spłatę kredytu wzrasta o 1 jednostke to ryzyko default rośnie ponad 4-krotnie.

Wysokie klasy ryzyka kredytowego (grade D, E, G) oraz wynajmowanie mieszkania również znacząco zwiększają ryzyko.

Z kolei posiadanie domu (OR = 0.63) oraz wyższe kwoty pożyczek (OR = 0.53) wiążą się z mniejszym prawdopodobieństwem niewypłacalności. Niektóre cele pożyczki, jak edukacja czy inwestycje, również obniżają ryzyko.

Random Forest

Random Forest osiągnął wysoką dokładność – Accuracy = 0.93 – co przekłada się na bardzo dobre rozpoznawanie klientów, którzy nie zalegają ze spłatą (6571 prawidłowych negatywów, precision = 0.93, recall = 0.98). Jednocześnie model radzi sobie całkiem dobrze z wykrywaniem rzeczywistych przypadków defaultu (1366 prawdziwych pozytywów, precision = 0.90), choć 27 % dłużników (511 z 1877) zostało przeoczonych (recall = 0.73). Zbalansowany wynik F1 (0.95 dla klasy 0 i 0.81 dla klasy 1) oraz wysoka wartość weighted avg (0.92) pokazują, że lasy losowe są skuteczną metodą predykcji ryzyka kredytowego.

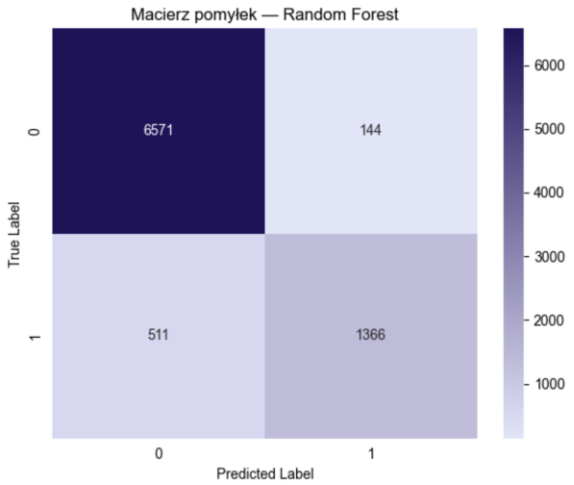


```
=== Wyniki Random Forest ===
Accuracy: 0.9238
              precision    recall  f1-score   support

           0       0.93      0.98      0.95      6715
           1       0.90      0.73      0.81      1877

    accuracy                           0.92      8592
   macro avg       0.92      0.85      0.88      8592
weighted avg       0.92      0.92      0.92      8592
```

Random Forest

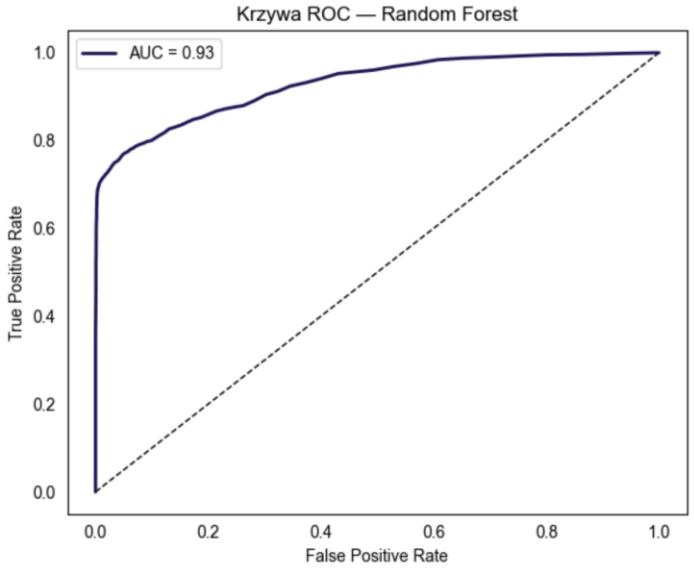

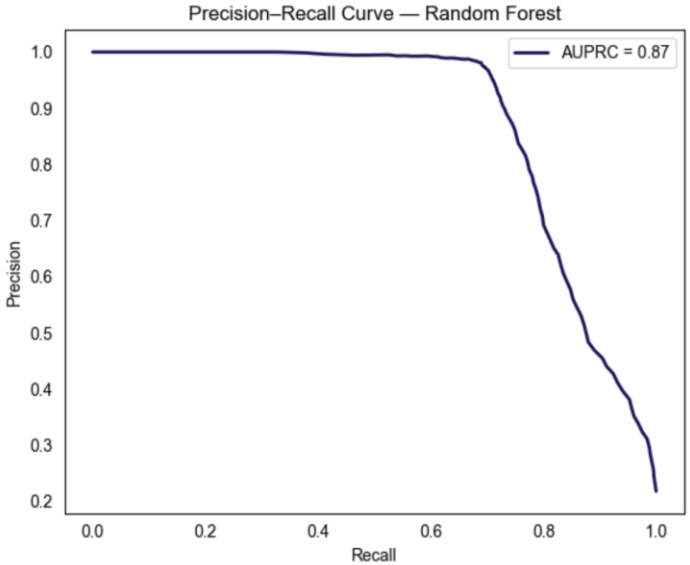

Doskonała zdolność modelu do rozróżniania dłużników od terminowo spłacających – krzywa znacząco wyprzedza przekątną losowości. Model zachowuje ponad 90 % precyzji aż do poziomu recall ≈ 0.8, co oznacza, że potrafi odnajdywać większość dłużników przy utrzymaniu niskiego odsetka fałszywych alarmów; dalsze zwiększanie czułości skutkuje już widocznym spadkiem precyzji.

XGBoost

Wydajny algorytm uczenia maszynowego oparty na drzewach decyzyjnych. Działa w oparciu o technikę boosting, czyli łączenie wielu prostych modeli (tzw. słabych uczniów) w jeden silny model. XGBoost jest znany z wysokiej dokładności, odporności na overfitting i szybkości działania.

XGBoost to zoptymalizowana wersja klasycznego Gradient Boostingu - wykorzystuje zaawansowane techniki, takie jak przycinanie drzewa (pruning) i równoległe przetwarzanie, co czyni go bardziej wydajnym i skalowalnym.

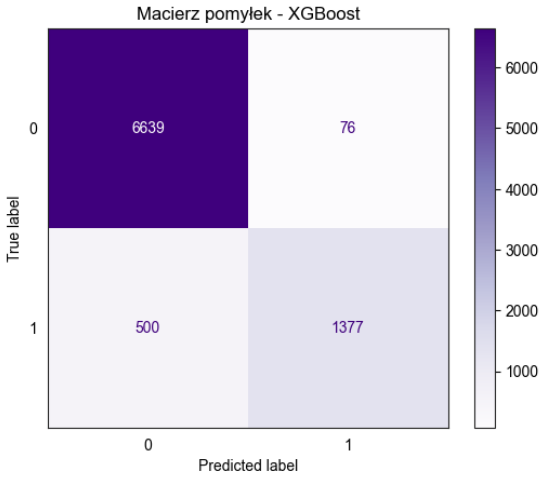


```
=== Wyniki XGBoost ===
Accuracy: 0.9330
              precision    recall  f1-score   support

           0       0.93      0.99      0.96      6715
           1       0.95      0.73      0.83      1877

    accuracy                           0.93      8592
   macro avg       0.94      0.86      0.89      8592
weighted avg       0.93      0.93      0.93      8592
```

XGBoost

ROC & Precision-Recall curve

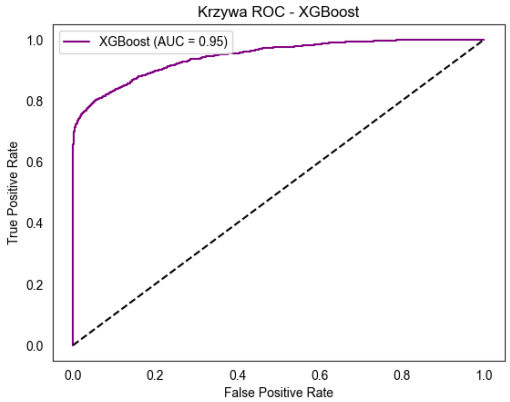

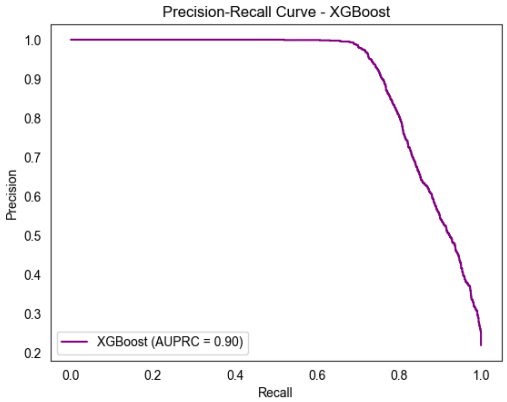

Model XGBoost osiągnął wysoką skuteczność klasyfikacji (accuracy: **93,3%**). Klasa 0 została rozpoznana bardzo dobrze — **f1-score: 0.96**, natomiast klasa 1 okazała się większym wyzwaniem. Model osiągnął **precision: 0.95** i **recall: 0.73**, co oznacza, że skutecznie wykrywa większość przypadków, choć nie wszystkie. Ogólnie model dobrze równoważy precyzję i czułość.

XGBoost

SHAP Summary plot & Feature Importance

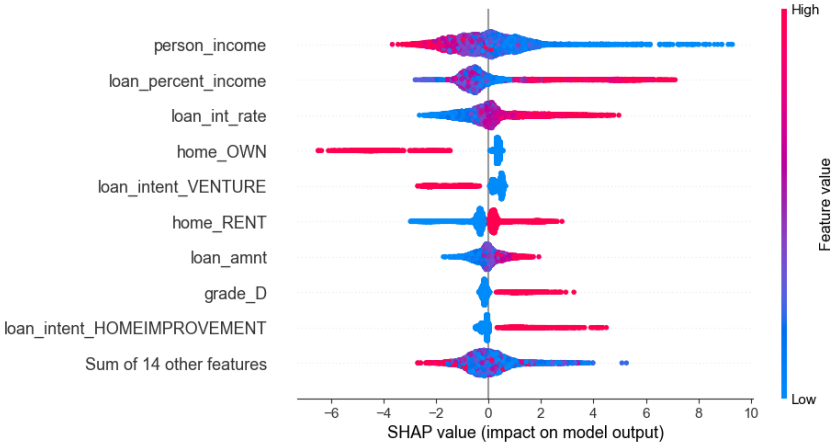

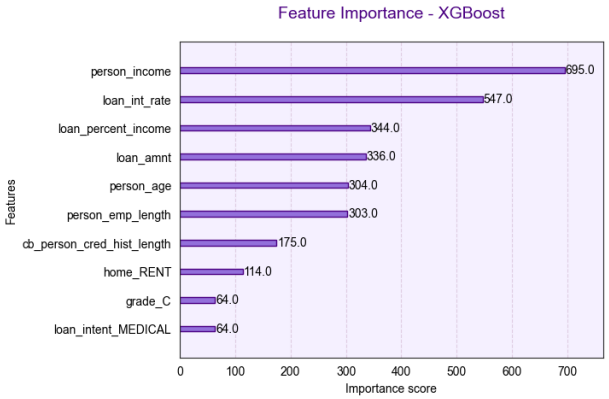

Najważniejszą cechą okazała się zmienna **person_income,** niski poziom tej zmiennej silnie zwiększa predykcje modelu.

Różnica w kolejności cech wynika z odmiennych sposobów pomiaru ich ważności XGBoost (prawy wykres) mierzy ją poprzez częstość użycia cechy do podziałów w drzewach, natomiast SHAP (wykres po lewej) oblicza średni bezwzględny wpływ cechy na ostateczną predykcję modelu.

XGBoost

SHAP Dependence Plot dla najważniejszych cech

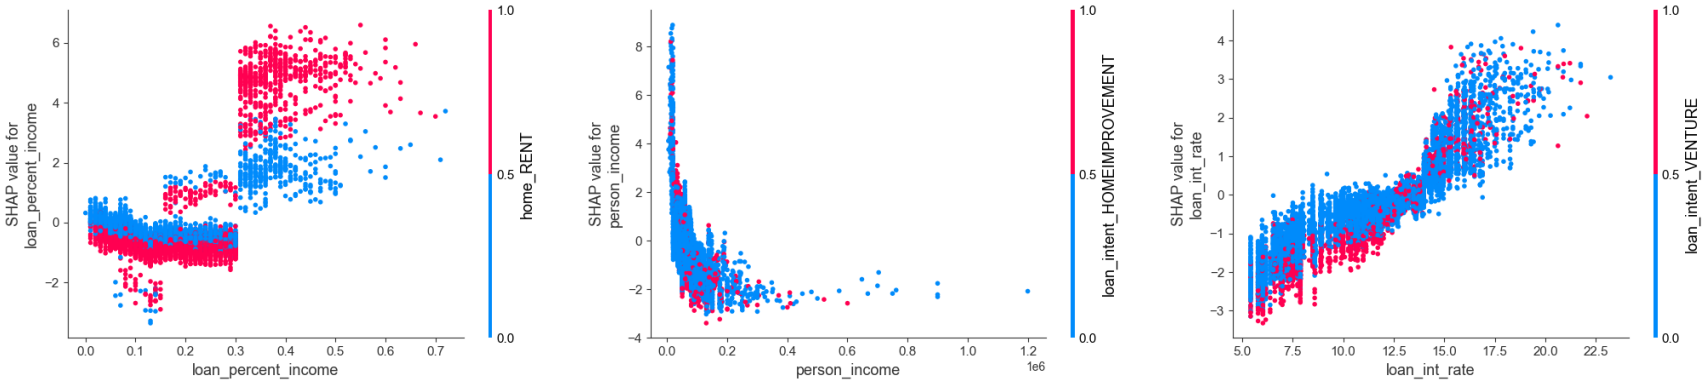

Wykresy SHAP Dependence ilustrują, jak poszczególne cechy wpływają na predykcje modelu, jednocześnie ujawniając istotne interakcje. Wysoki **loan_percent_income** silnie zwiększa predykcję, szczególnie przy niskich dochodach (**person_income**). Z kolei wysoki **person_income** zmniejsza predykcję, ale efekt ten jest łagodzony, gdy występuje **home_RENT**, podobnie jak wysoka **loan_int_rate** i **loan_intent_VENTURE** wzajemnie wzmacniają wpływ na predykcję.

LightGBM

LightGBM to ekstremalnie szybki algorytm boostingowy opracowany przez Microsoft, zaprojektowany z myślą o dużych zbiorach danych i niskim czasie uczenia. W odróżnieniu od XGBoost, LightGBM nie buduje drzew poziomami (depth-wise), lecz **liśćmi (leaf-wise)** — co oznacza, że rozwija najbardziej obiecujące gałęzie, prowadząc do lepszej optymalizacji błędu, ale też większego ryzyka overfittingu. Dodatkowo, używa **histogram-based learning** – cechy numeryczne są grupowane w przedziały (biny), co redukuje zużycie pamięci i przyspiesza obliczenia.

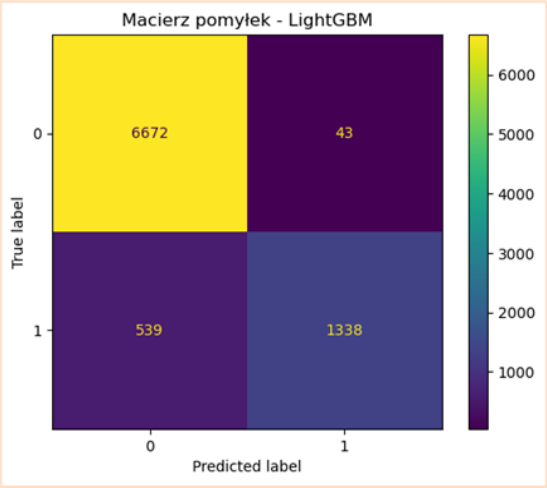


```
=== Wyniki LightGBM ===
Accuracy: 0.9323
              precision    recall  f1-score   support

           0       0.93      0.99      0.96      6715
           1       0.97      0.71      0.82      1877

    accuracy                           0.93      8592
   macro avg       0.95      0.85      0.89      8592
weighted avg       0.93      0.93      0.93      8592
```

LightGBM

ROC & Precision-Recall curve

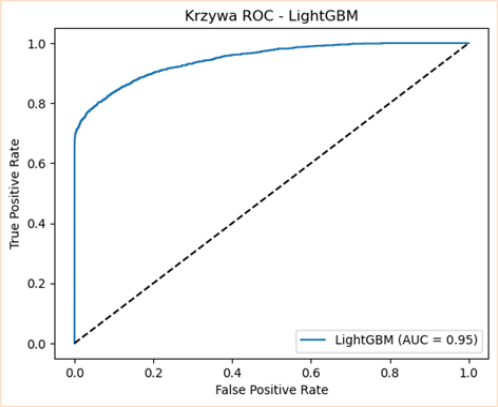

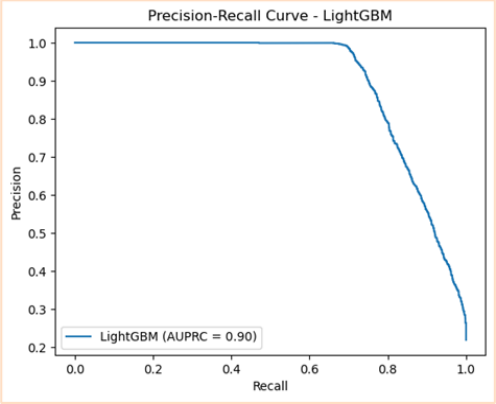

Model LightGBM osiągnął wysoką skuteczność klasyfikacji (accuracy: **95%**). Klasa 0 (np. brak niewypłacalności) została rozpoznana bardzo dobrze — **f1-score: 0.96**, natomiast klasa 1 (np. niewypłacalność) jest trudniejsza, ale model osiągnął **precision: 0.97** i **recall: 0.71**, co oznacza, że skutecznie wykrywa większość przypadków, choć nie wszystkie. Ogólnie model dobrze równoważy precyzję i czułość.

LightGBM

SHAP Summary plot & Feature Importance

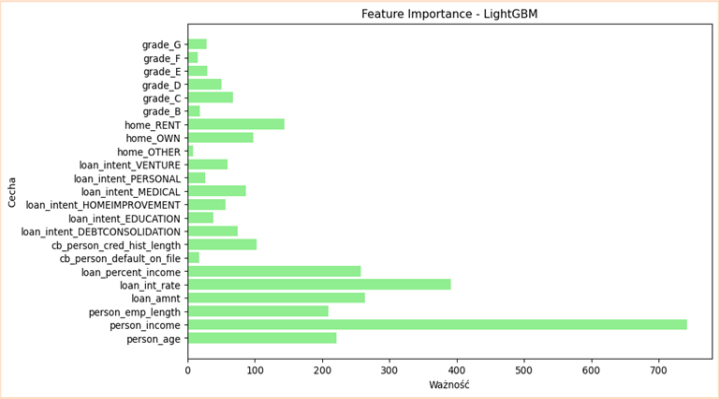

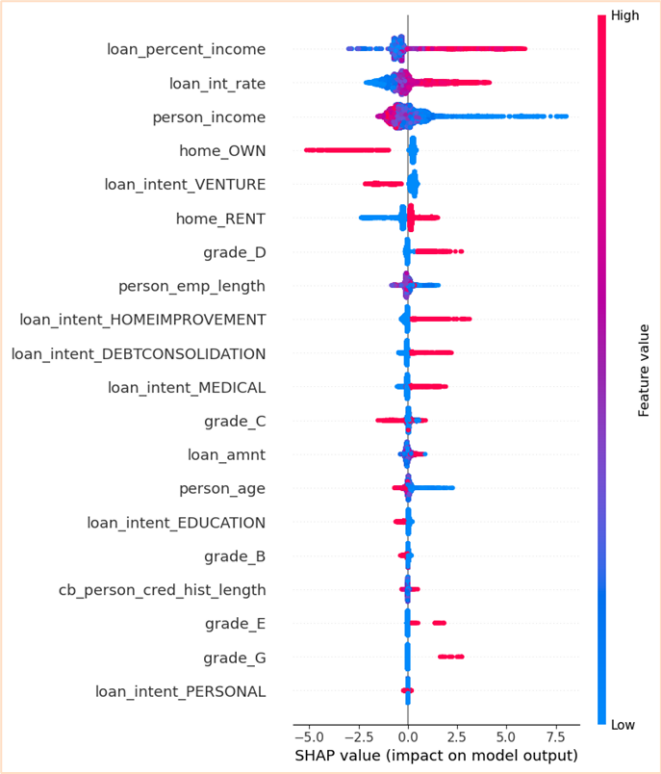

Dochód kredytobiorcy (***person_income***), oprocentowanie kredytu (***loan_int_rate***), kwota kredytu (***loan_amnt***), oraz stosunek zadłużenia do dochodu (***loan_percent_income***) mają największy wpływ na ryzyko *defaultu*, co potwierdza analiza *Feature Importance*.

Wykres SHAP pokazuje, że wysokie wartości ***loan_percent_income*** i ***loan_int_rate*** znacząco zwiększają ryzyko niespłacenia kredytu, podczas gdy wysokie dochody (***person_income***) oraz posiadanie własnego mieszkania skutecznie (***home_OWN***) je obniżają.

Categorical Boosting (CatBoost)

CatBoost to nowoczesny algorytm boostingowy opracowany przez firmę Yandex, zoptymalizowany do pracy z danymi zawierającymi wiele zmiennych kategorycznych. W przeciwieństwie do XGBoost, **automatycznie przetwarza zmienne kategoryczne**, bez potrzeby ich kodowania. Wyróżnia go też zastosowanie **Ordered Boosting** — techniki, która symuluje predykcję w warunkach rzeczywistych, eliminując przeciekanie informacji (leakage) i zmniejszając bias. CatBoost korzysta również z własnych metod regularyzacji, które ograniczają nadmierne dopasowanie (overfitting), zapewniając stabilne i dokładne modele bez potrzeby intensywnego tuningu. Jest szczególnie przydatny przy danych z wieloma kategoriami i mniejszą liczbą obserwacji.

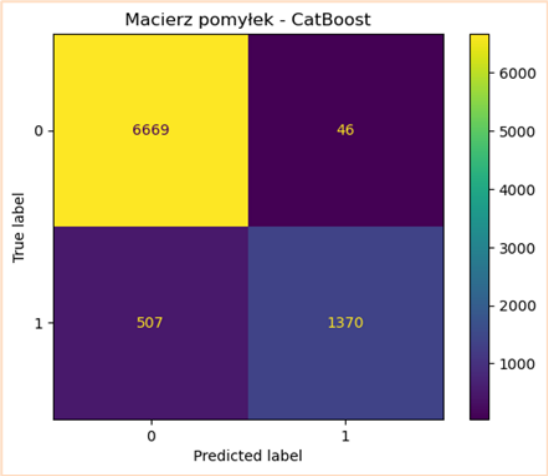


```
=== Wyniki CatBoost ===
Accuracy: 0.9356
              precision    recall  f1-score   support

           0       0.93      0.99      0.96      6715
           1       0.97      0.73      0.83      1877

    accuracy                           0.94      8592
   macro avg       0.95      0.86      0.90      8592
weighted avg       0.94      0.94      0.93      8592
```

CatBoost

ROC & Precision-Recall curve

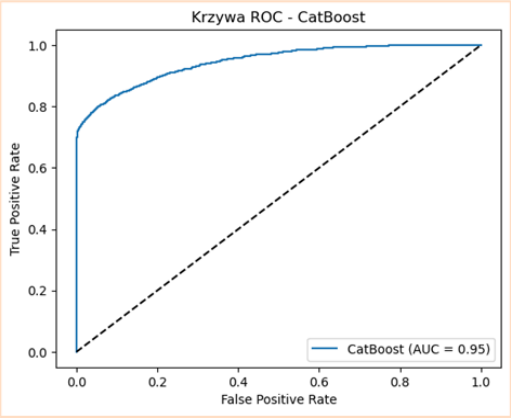

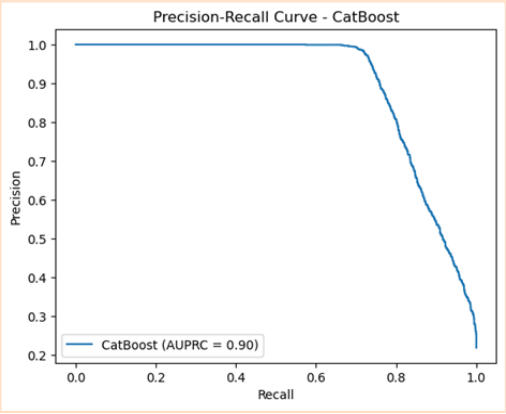

Model CatBoost osiągnął najwyższą skuteczność klasyfikacji (accuracy: **95%**). Klasa 0 (np. brak niewypłacalności) została rozpoznana bardzo dobrze — **f1-score: 0.96**, natomiast klasa 1 (np. niewypłacalność) jest trudniejsza, ale model osiągnął **precision: 0.97** i **recall: 0.73**, co oznacza, że skutecznie wykrywa większość przypadków, choć nie wszystkie. Ogólnie model dobrze równoważy precyzję i czułość.

CatBoost

SHAP Summary plot & Feature Importance

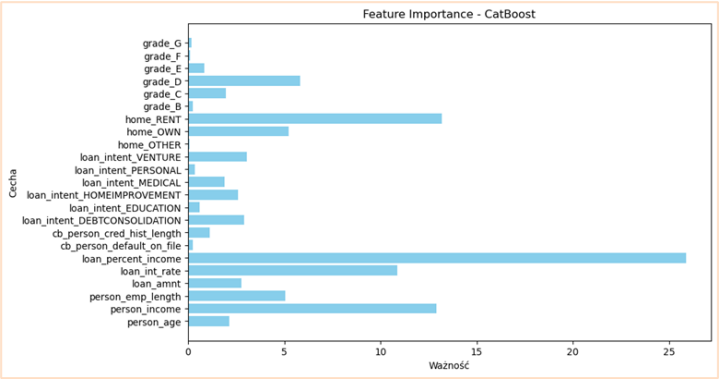

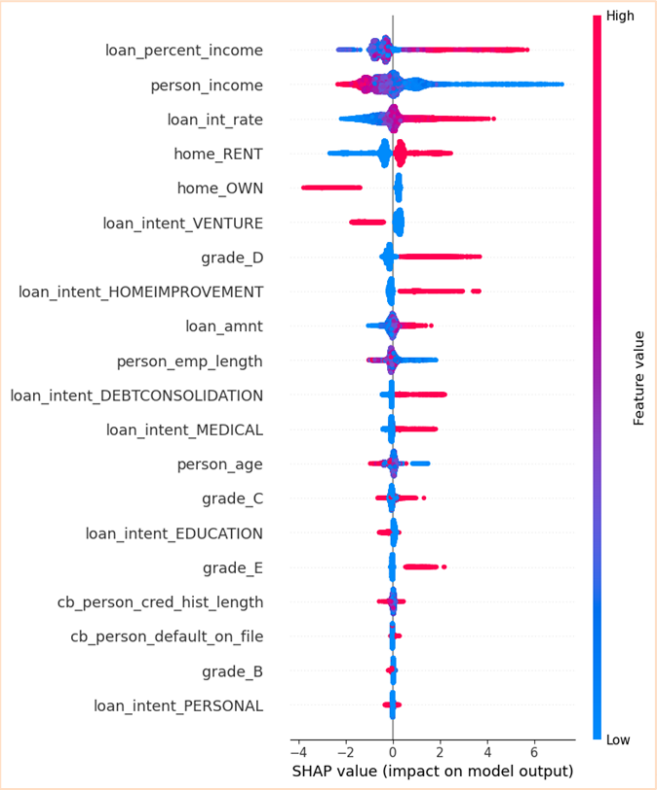

Model CatBoost wskazuje, że największy wpływ na ryzyko defaultu mają: ***loan_percent_income***, ***person_income*** oraz ***loan_int_rate***.

W przypadku ***loan_percent_income*** oraz ***loan_int_rate*** ryzyko *defaultu* rośnie wraz ze wzrostem tych zmiennych, a wraz ze wzrostem ***person_income*** maleje.

Multi-Layer Percepron (MLP)

Model MLP skutecznie klasyfikuje przypadki **bez zaległości**, osiągając wysoką precyzję (0,92) i Accuracy (0,86).

Jednak jego efektywność w wykrywaniu przypadków **z zaległościami** jest niższa, co potwierdza recall klasy 1 = 0,71.

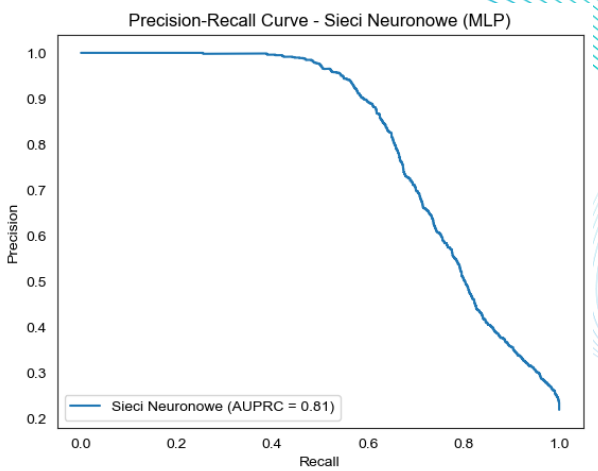

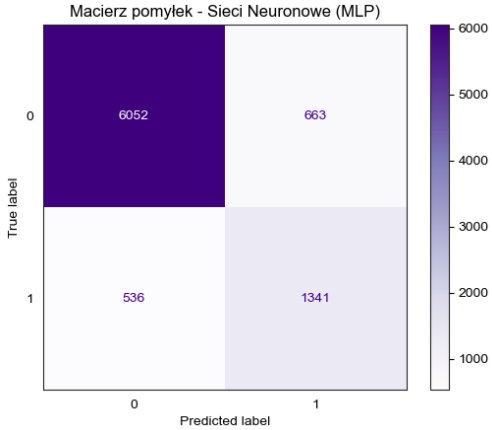

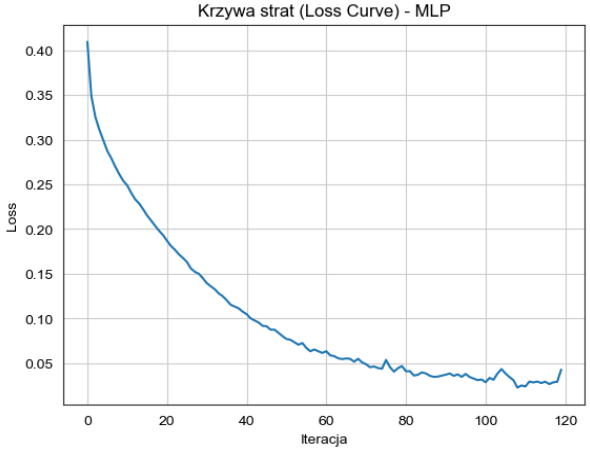

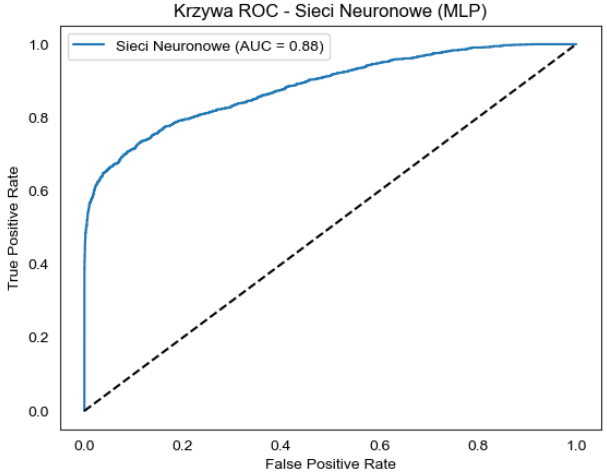

Multi-Layer Percepron (MLP)

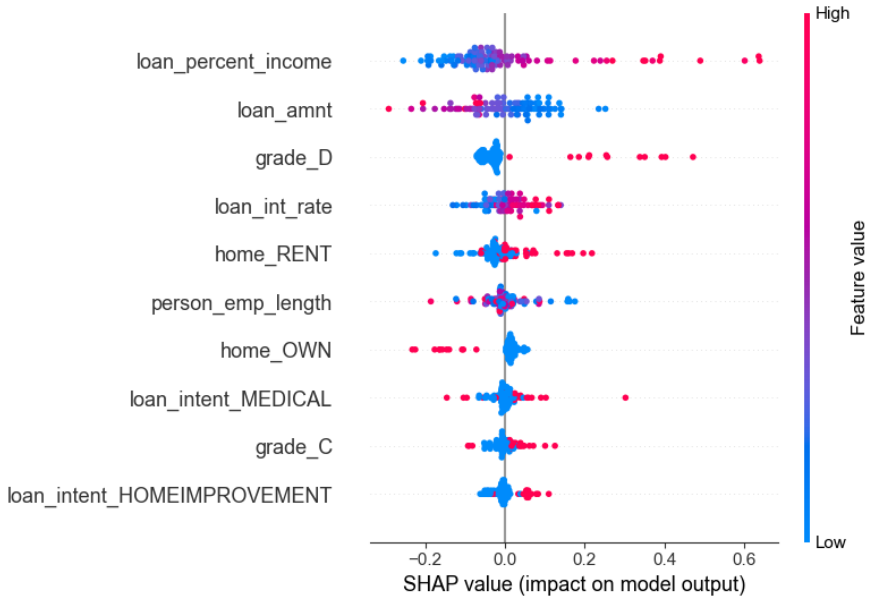

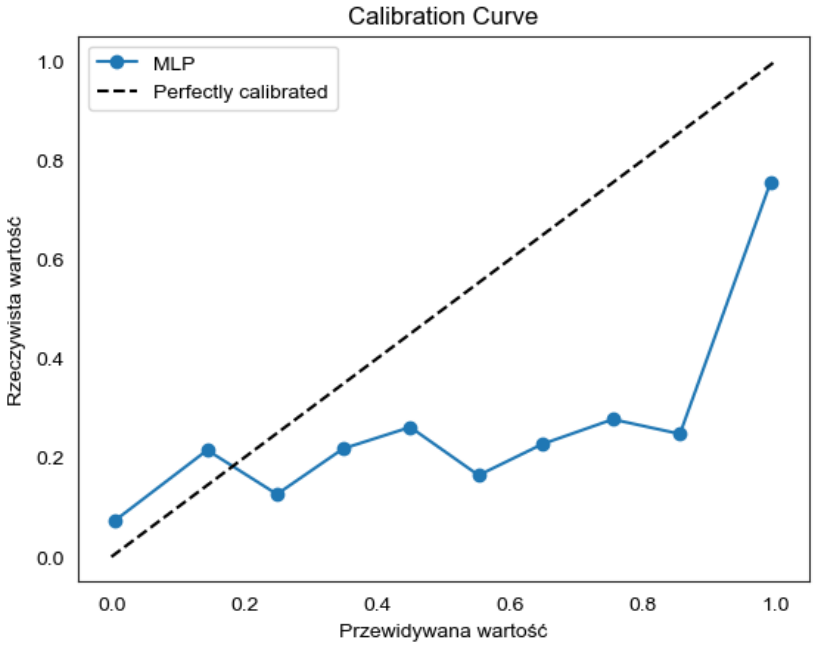

Sieć neuronowa TabNet

TabNet osiągnął accuracy 91% i dobrą równowagę między klasami (F1 = 0.77 dla klasy 1).

Model wykorzystuje mechanizm uwagi (attention), by selektywnie skupiać się na istotnych cechach przy każdej decyzji.

Dzięki temu efektywnie działa na danych tabelarycznych bez konieczności intensywnego przetwarzania wstępnego.

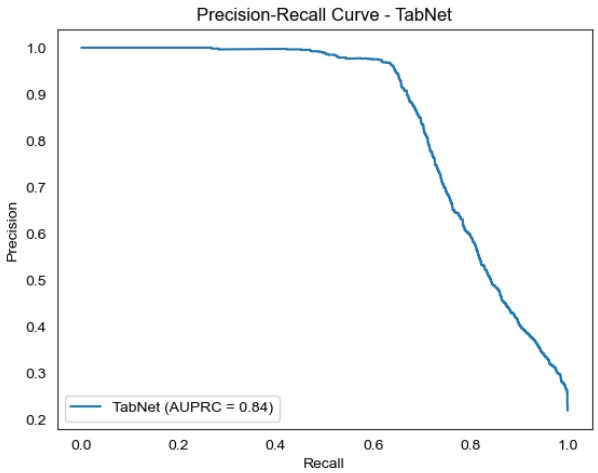

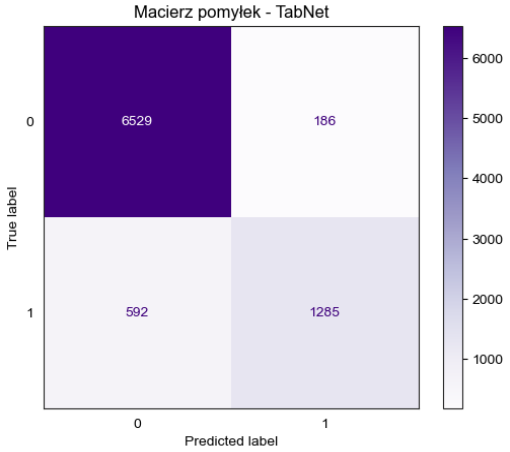

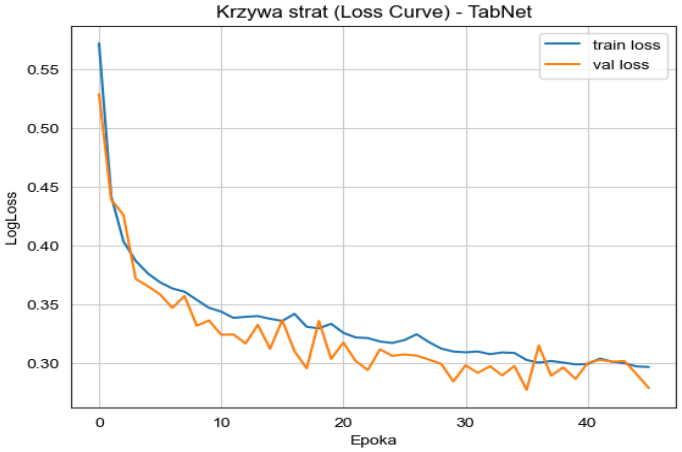

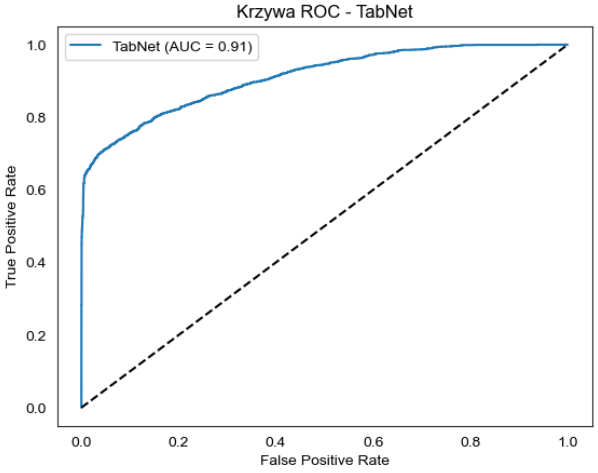

Sieć neuronowa TabNet

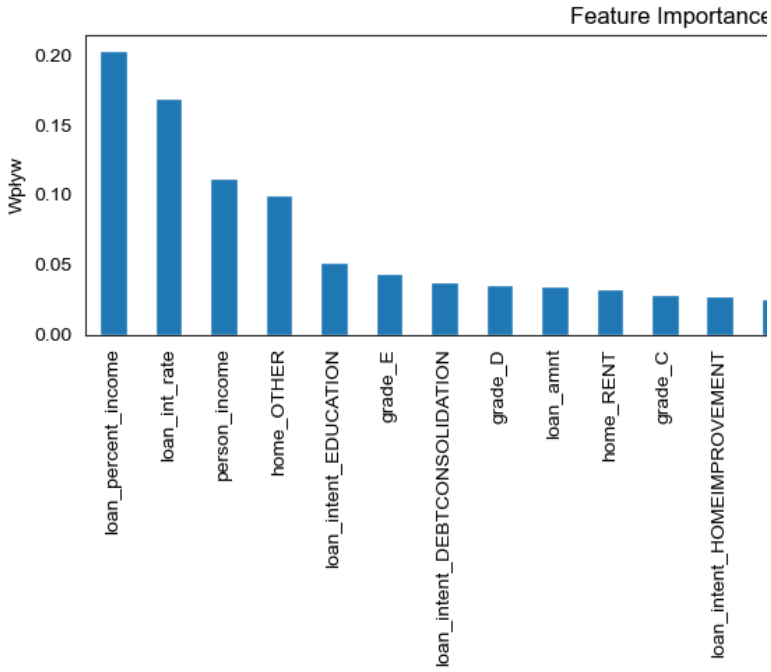

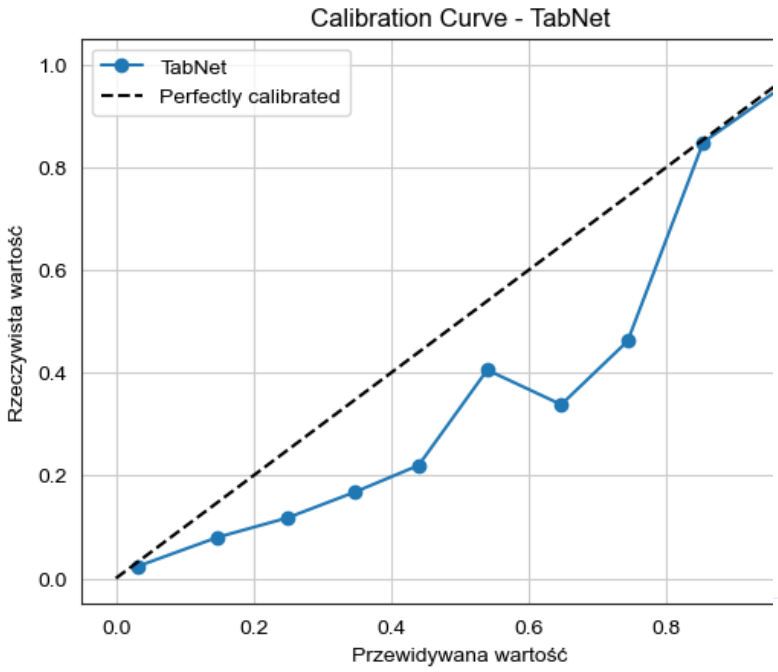

Wnioski dotyczące zmiennych

Czynniki zwiększające prawdopodobieństwo *defaultu*

- **loan_percent_income** - dodatkowy procent dochodu przeznaczony na spłatę kredytu
- **loan_int_rate** - wyższe oprocentowanie kredytu
- **grade** - niższa ocena kredytowa (D, E, G, F, C)
- **home_RENT** – wynajem mieszkania
- **loan_intent** - przeznaczenie kredytu na konsolidację zadłużenia, ulepszenie domu lub cele medyczne

Czynniki zmniejszające prawdopodobieństwo *defaultu*

- **person_income** - wyższy dochód
- **person_emp_length** - wyższa długość zatrudnienia
- **person_age** - wyższy wiek
- **loan_amnt** - większa kwota kredytu
- **home_OWN** – posiadanie własnego mieszkania
- **loan_intent** – przeznaczenie kredytu na działalność gospodarczą, lub na edukację

Wybór modelu

Na podstawie przeprowadzonej analizy porównawczej wybrano model CatBoost jako najbardziej skuteczny algorytm do przewidywania ryzyka kredytowego.

Model ten osiągnął najwyższą dokładność (93,6%), bardzo wysoką precyzję (96,7%) oraz zrównoważony wynik F1 (0,83), co czyni go najefektywniejszym rozwiązaniem w zakresie identyfikacji przypadków defaultu przy jednoczesnym ograniczeniu liczby fałszywych alarmów.

Rekomendacja biznesowa

Wdrożenie modelu CatBoost może istotnie usprawnić proces oceny ryzyka kredytowego, umożliwiając wcześniejsze i trafniejsze wykrywanie klientów o podwyższonym prawdopodobieństwie zaległości.

Dzięki temu instytucja finansowa może ograniczyć straty związane z udzielaniem kredytów osobom potencjalnie niewypłacalnym oraz zwiększyć efektywność zarządzania portfelem kredytowym.